สรุปภาพรวม: ระบบรวมข้อมูลร้านอาหาร จังหวัดนครปฐม

02739452 แพลตฟอร์มข้อมูลขนาดใหญ่และการวิเคราะห์ · สอบปลายภาค ภาคต้น 2569 · ลำดับที่ 23 · รหัสนิสิต 6621655258
GitHub: https://github.com/Bestzxc/02739452-23-6621655258 · วิธีรัน: `cp .env.example .env` แล้ว `docker compose up -d --build` (รายละเอียดใน README)

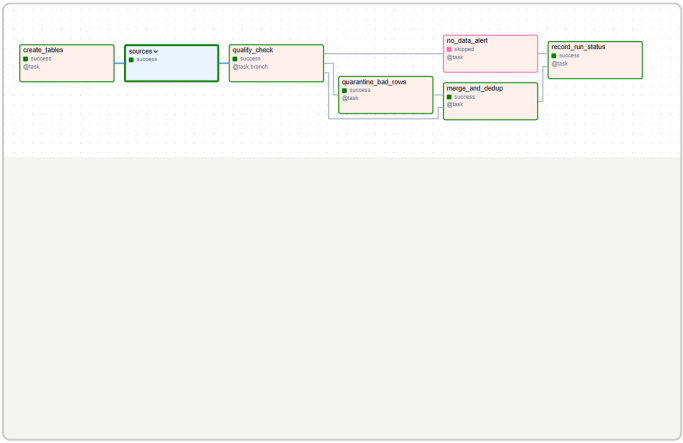
1. ภาพรวมงานแต่ละส่วน — ทำได้ถึงระดับ 3 + โบนัสทั้ง 2 ข้อ

ขอบเขต: ร้านอาหารและคาเฟ่ใน จ.นครปฐม ครบ 7 อำเภอ · เก็บเฉพาะข้อมูลระดับร้าน (ไม่เก็บข้อความรีวิวหรือข้อมูลผู้ใช้ ตาม PDPA)

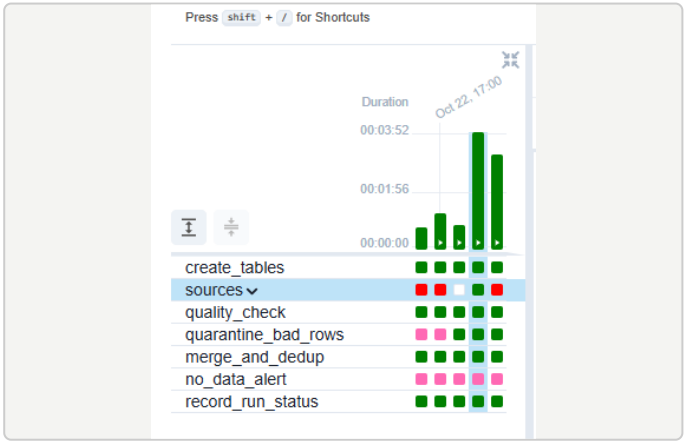
#	แหล่งข้อมูล	วิธีดึง	ได้อะไร
1	Wongnai	**Web scraping** ด้วย requests + BeautifulSoup (ไม่ใช้ Selenium) อ่าน JSON ที่ฝังในหน้า · ตรวจ robots.txt ก่อนทุก request · เว้น 2 วินาที	ชื่อ ประเภท คะแนน จำนวนรีวิว ช่วงราคา พิกัด
2	OpenStreetMap	Overpass API (ไม่ต้องใช้ key)	ชื่อ ประเภทอาหาร พิกัด ที่อยู่
3	Overture Maps Places	อ่าน GeoParquet บน S3 สาธารณะด้วย DuckDB กรองด้วย bbox + หมวด food_and_drink (ฟรี ไม่ต้องใช้ key)	ชื่อ ประเภท พิกัด ที่อยู่ เว็บไซต์

ระดับ	สิ่งที่ทำ	สถานะ
1	DAG `restaurant_pipeline`: extract → transform → load → PostgreSQL → เว็บ Streamlit มีตารางและกราฟ	✓ ผ่าน
2	3 แหล่งรันขนานกันใน TaskGroup `sources` · แปลงเป็น schema เดียว (13 ฟิลด์) · `INSERT … ON CONFLICT (source, source_id) DO UPDATE` รันซ้ำแล้วจำนวนแถวไม่เพิ่ม · เว็บมี KPI 4 การ์ดและตัวกรอง (อำเภอ ประเภท แหล่ง คะแนนดาว คำค้น)	✓ ผ่าน
3	`trigger_rule=all_done` ทำให้รวมข้อมูลต่อได้แม้บางแหล่งล่ม (รอบล่าสุด Wongnai อ.ดอนตูม ล้ม → สถานะ partial แต่ยังรวมข้อมูลได้) · ตัดรายการซ้ำข้ามแหล่งด้วยชื่อคล้ายกัน ≥ 85% (rapidfuzz) + ห่างกัน ≤ 150 ม. · ตรวจคุณภาพแล้วแตกเส้นทางด้วย `@task.branch` → แถวไม่ผ่านไป `rejected_listings`	✓ ผ่าน
โบนัส	Dynamic Task Mapping (`extract.expand(area=AREAS)` 7 อำเภอ) และหน้า Pipeline Status บนเว็บ	✓ ทั้งคู่

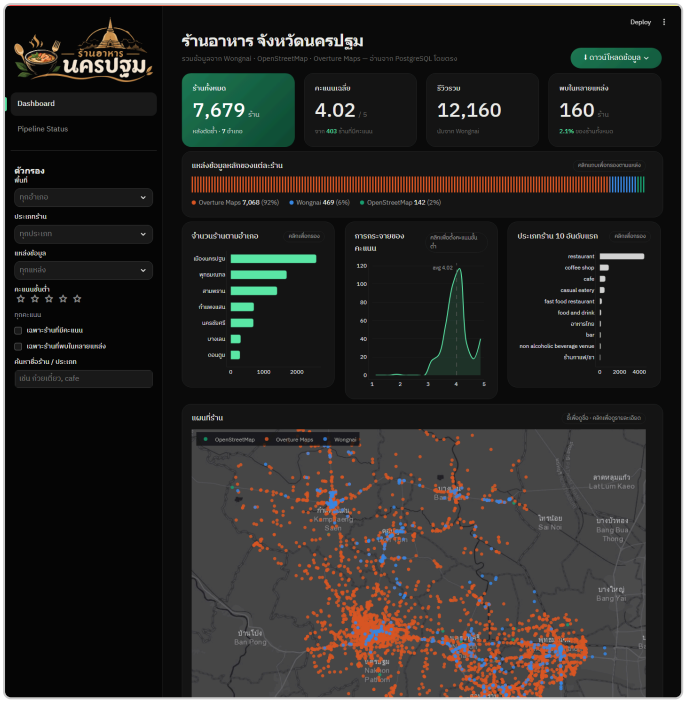
ผลรอบล่าสุด: staging 7,928 แถว → ผ่าน QC 7,848 (ไม่ผ่าน 80 เช่น ร้านโฆษณานอกพื้นที่) → **7,679 ร้าน**หลังตัดซ้ำ (พบในหลายแหล่ง 160 ร้าน) — เกินข้อกำหนด 100 รายการ



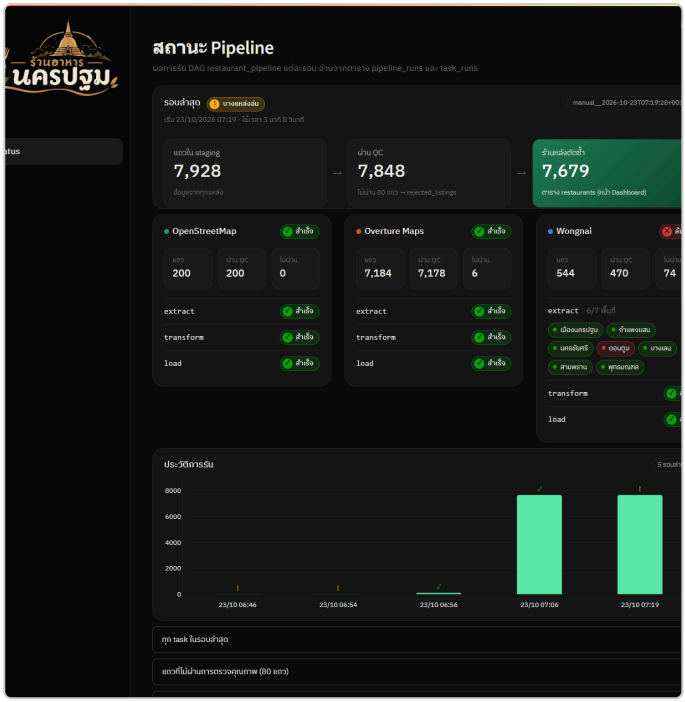
รูปที่ 1 Graph view ของ DAG (TaskGroup sources 3 แหล่ง → quality_check branch → merge_and_dedup)



รูปที่ 2 Grid view ผลการรันแต่ละรอบ: รอบแรก ๆ กลุ่ม sources ล่ม (Wongnai) แต่ quality_check / merge_and_dedup ยังทำงานต่อ



รูปที่ 3 หน้า Dashboard: KPI, สัดส่วนแหล่งข้อมูล (คลิกเพื่อกรอง), กราฟ 3 แบบ, แผนที่ร้าน (ชี้ดูชื่อ · คลิกดูรายละเอียด), ดาวน์โหลด CSV / Excel / SQL / JSON



รูปที่ 4 หน้า Pipeline Status: สถานะรอบล่าสุด, จำนวนแถวแต่ละขั้น, สถานะ task แยกแหล่ง/อำเภอ, ประวัติการรัน

2. ปัญหาที่พบและวิธีแก้

ปัญหาที่ 1 — Wongnai ดึงไม่ได้ทั้งที่ robots.txt อนุญาต

อาการ task `sources.wongnai.extract` ล้มทุกพื้นที่ด้วย `RobotsDisallowed` ข้อมูลทั้งระบบเหลือ 14 ร้าน (ต่ำกว่า 100)
หาสาเหตุ อ่าน log ของ task ใน Airflow → เปิด robots.txt จริงพบว่าห้ามแค่ `/users/` → ทดสอบใน container พบว่า `robotparser.read()` ใช้ User-Agent ของ urllib แล้วเว็บตอบ 403 ซึ่ง robotparser ตีความว่า "ห้ามทุกหน้า"
วิธีแก้ โหลด robots.txt ด้วย requests + User-Agent ของโปรเจกต์ แล้วส่งให้ `rp.parse()` เอง (ยังเคารพ robots.txt เหมือนเดิม)

ปัญหาที่ 2 — หน้าเว็บโหลดได้ (HTTP 200) แต่ parse ได้ 0 ร้าน และหน้า 2 ซ้ำหน้า 1

อาการ extract ได้ HTML 560 KB แต่ parser คืน 0 รายการ · พอแก้แล้ว หน้า 2–5 ได้ร้านชุดเดิม
หาสาเหตุ บันทึก HTML ออกมาไล่ดู script ทั้งหมด พบว่าข้อมูลร้านอยู่ใน `window._wn = {…}` ไม่ใช่ `__NEXT_DATA__` ที่เตรียมไว้ · ค้นคีย์ที่เกี่ยวกับหน้าใน state พบว่าเว็บใช้ `page.number` ไม่ใช่ `page`
วิธีแก้ เพิ่มการอ่าน `window._wn` ด้วย `json.JSONDecoder().raw_decode` และเปลี่ยน URL เป็น `page.number` → ได้ ~10 ร้านใหม่ต่อหน้า

ปัญหาที่ 3 — load ล้ม: "ON CONFLICT DO UPDATE command cannot affect row a second time"

อาการ extract/transform ผ่าน แต่ `wongnai.load` ล้มทุกครั้ง
หาสาเหตุ อ่าน error ใน log → ร้านเดียวกัน (เช่น ร้านโขษณา) โผล่ในผลค้นหาหลายอำเภอ ทำให้ key `(source, source_id)` ซ้ำกันใน INSERT คำสั่งเดียว
วิธีแก้ ตัดแถวที่ key ซ้ำออกก่อน UPSERT (เก็บแถวเดียวต่อ key)

ปัญหาที่ 4 — แหล่งที่ 3 (Google Places) ต้องผูกบัตร และแผนที่หายเมื่อซูมใกล้

อาการ Google Places ไม่มี key → ถูกข้ามทุกรอบ · บนเว็บซูมเกินระดับ 16 แผนที่กลายเป็นภาพ "Map data not yet available"
หาสาเหตุ Google Places ต้องเปิด billing · ยิงขอ tile ของ Esri ทีละระดับ พบว่าตั้งแต่ระดับ 17 ได้ภาพเดียวกันหมด (ไม่มีข้อมูล)
วิธีแก้ เปลี่ยนแหล่งที่ 3 เป็น Overture Maps (open data ฟรี อ่านด้วย DuckDB) · ตั้ง maxzoom ของ tile เป็น 16 ให้แผนที่ขยายภาพระดับ 16 แทน และจำกัดการซูมที่ 17.5

3. การวางแผนและจัดลำดับงาน

หลักที่ใช้: ทำให้ **ส่วนที่มีคะแนน (pipeline ระดับ 1–3) ทำงานครบและ push ขึ้น GitHub ก่อน** แล้วค่อยขยายขอบเขตและแต่งเว็บ — commit ทุกช่วงที่ระบบใช้ได้ เพื่อไม่ให้งานที่ทำแล้วเสี่ยงหายหากหมดเวลา

เวลา	งาน	commit
ก่อนสอบ	เตรียมโครง DAG, schema, ตัดซ้ำ, หน้าเว็บ และ docker-compose ไว้ (ส่วนที่ต้องดูหน้าเว็บจริงทำเป็น TODO วันสอบ)	–
13:00–13:50	จองหัวข้อ เปิดระบบ รัน DAG รอบแรก → พบว่า Wongnai ล้ม ได้แค่ 14 ร้าน	–
13:50–14:00	แก้ปัญหาที่ 1–3 จนได้ 127 ร้าน (ผ่านขั้นต่ำ 100) → สร้าง repo และ push ทันที	14:00
14:00–14:11	ขยายเป็นทั้งจังหวัด 7 อำเภอ · เปลี่ยน Google Places เป็น Overture Maps → 7,679 ร้าน	14:11
14:11–15:26	ปรับหน้าเว็บ: ธีม, แผนที่ (hover/คลิก/ล็อกขอบเขต/แผงรายละเอียด), ตัวกรอง, ดาวน์โหลด CSV/Excel/SQL, หน้า Pipeline Status	14:23, 14:29, 15:16, 15:26
15:26–16:00	เขียนสรุป PDF นี้ · ตรวจ repo	–

งานที่ตัดออก และเหตุผล

- **Google Places API** — ต้องผูกบัตรเครดิต จึงเปลี่ยนเป็น Overture Maps ที่ฟรี ซึ่งได้ร้านมากกว่า (7,184 แถว) แต่ไม่มีคะแนนรีวิว
- **รวมชื่อประเภทร้านไทย/อังกฤษให้เป็นชุดเดียว** (เช่น cafe / coffee shop / ร้านกาแฟ/ชา) — ต้องทำตารางแปลงชื่อด้วยมือ ใช้เวลามาก จึงทำแค่แยกประเภทที่คั่นด้วย , และ ; และซ่อนประเภทที่มีไม่ถึง 3 ร้าน
- **คะแนนจากแหล่งอื่นนอกจาก Wongnai** — OSM และ Overture ไม่มีข้อมูลนี้ คะแนนเฉลี่ยจึงคิดจาก 403 ร้านที่มีคะแนนเท่านั้น
- **คลิกกราฟเพื่อกรองซ้ำหลายครั้ง** — ครั้งแรกใช้ได้ แต่ครั้งถัดไปในหน้าเดิมยังไม่ติด ไม่ทันหาสาเหตุ จึงให้ใช้ตัวกรองใน sidebar แทน (ใช้ได้ทุกช่อง)
- **ดึง Wongnai หลายหน้ากว่านี้** — ตั้งไว้ 8 หน้า/อำเภอ เพราะต้องเว้น 2 วินาทีต่อ request ตามมารยาทการ scrape ถ้าเพิ่มหน้า DAG จะรันนานขึ้นมาก

สิ่งที่เรียนรู้

การอ่าน log ของแต่ละ task ใน Airflow ช่วยหาสาเหตุได้เร็วกว่าการเดา · การ commit ทันทีที่ระบบผ่านขั้นต่ำช่วยลดความเสี่ยงเรื่องเวลา · `trigger_rule=all_done` ทำให้เห็นผลจริงตอนแหล่งหนึ่งล่ม (รอบล่าสุดสถานะ partial แต่ dashboard ยังมีข้อมูลครบจากแหล่งที่เหลือ)